Exercício de replicação de análise estatística

Metodologia de Pesquisa II - Márcio Barros

"Automatic Generation of Regular Expressions for the Regex Golf Challenge using a Local Search Algorithm", André de Almeida Farzat, Márcio de Oliveira Barros, Genetic Programming and Evolvable Machines Journal, 2021

Formato dos arquivos

Temos resultados calculados para 50 rodadas (numeradas de 0 a 49), cada qual representada em um diretório. Dentro do diretório de uma rodada, temos dois arquivos para cada instância. O primeiro arquivo, com o nome da instância tem as informações dos eventos ocorridos durante o processo de cálculo. Este arquivo possui as seguintes colunas:

- Index: índice da iteração em que ocorreu o evento;
- Event Name: nome do evento;
- Regex: expressão regular resultante da aplicação do operador;
- Operator Name: tipo de operador;
- Arg for Operator: argumento aplicado ao operador (ignorar);
- Regex Origin: expressão regular antes da aplicação do operador;
- Fitness: indicador de qualidade da expressão regular resultante (quanto maior melhor).

O segundo arquivo possui informações relacionadas à aplicação do algoritmo redutor de expressões regulares, sendo composto pelas seguintes colunas:

- Event Name: nome do evento;
- Operation Name: tipo de operação;
- Index: índice da iteração em que ocorreu o evento;
- Node: transformação ocorrida (ignorar);
- Result Is Better: indica se a qualidade da solução melhorou depois do evento (vazio igual a *false*).

Além disso, temos um arquivo “instances.csv” com os dados das instâncias:

- Instance: nome da instância;
- Matchlist: número de entradas na match list;
- Unmatchlist: número de entradas na unmatch list;
- Weight: peso da instância;
- Maxrank: maior valor possível para a qualidade da instância;
- Norvig: qualidade máxima atingida pelo algoritmo de Norvig;

- Bartolli: qualidade máxima atingida pelo algoritmo de Bartolli;
- Humans: qualidade máxima atingida por uma solução desenvolvida por humanos;
- Order: número de sequência para apresentação nas tabelas.

Objetivos

1) Gerar as análises que produzem os resultados da Tabela 10.
    a. Dados das instâncias, resultados de Norvig, Bartolli e humanos vindos do arquivo base;
    b. Maior resultado da busca local para cada instância calculado pelos arquivos de processo. Esta informação é calculada como o maior valor de fitness apresentado na última linha de cada arquivo da busca local de uma instância;
    c. Resultados médios e desvio padrão da busca local calculados pelos arquivos de processo. Estas duas informações são calculadas pelo valor de fitness apresentado na última linha de cada arquivo da busca local de uma instância;
    d. Teste estatístico comparando os resultados da busca local de cada instância (50 valores de fitness) aos valores de fitness produzidos pelos outros algoritmos (1 valor por algoritmo).

2) Gerar as análises que produzem os resultados da Figura 4 com base nos arquivos do processo.
    a. Pega o maior valor de fitness para cada instância em cada rodada;
    b. Desenha os boxplots por instância.

3) Gerar as análises que produzem os resultados da Tabela 11 com base nos arquivos do redutor.
    a. COUNT: número de eventos de encerramento de shrink
    b. EFFECTIVE: número de eventos de encerramento de shrink com melhoria de qualidade
    c. % EFFEC: EFFECTIVE dividido por COUNT
    d. Colunas de operadores: número de vezes que os operadores foram utilizados

4) Gerar as análises que produzem os resultados da Tabela 12 com base nos arquivos do processo. As colunas de operadores indicam o número de vezes que os operadores foram utilizados nas linhas que o evento é “Found better in current neighborhood”.

5) Gerar as análises que produzem os resultados da Tabela 13 com base nos arquivos do processo. As colunas de operadores indicam o ganho de fitness provocado por cada operador, com base na diferença entre o fitness registrado depois da aplicação do operador em eventos do tipo "Found better in current neighborhood" e o fitness registrado no último evento “Start of neighborhood” anterior ao evento que provocou a melhoria.